

Balanceamento de Carga por Eventos Discretos para um Sistema Distribuído com Tráfego Bounded Pareto

Rodrigo Camargo André Loubet
RA 238257 RA 253333

MC714, Sistemas Distribuídos, Universidade Estadual de Campinas

Resumo. Este trabalho implementa e avalia um balanceador de carga para três servidores. O simulador orientado a eventos discretos recebe rajadas Bounded Pareto e compara as políticas Aleatória, Round Robin e Fila Mais Curta. Cada servidor homogêneo executa até quinze requisições simultâneas, com serviço determinístico de 0,05. Cada cenário usa horizonte fixo de 200 unidades e dez repetições. A análise emprega um modelo transiente de lote finito com roteamento justo, evitando hipóteses de regime estacionário incompatíveis com a rajada. Como extensões, são avaliados servidores heterogêneos, Round Robin Ponderado, Trabalho Mínimo, Poder de Duas Escolhas, backup para estouro de buffers e uma arquitetura hierárquica de dois níveis.

Index Terms. Balanceamento de carga, simulação de eventos discretos, Bounded Pareto, modelo transiente, sistemas distribuídos.

I. INTRODUÇÃO

O trabalho modela um front-end que recebe uma rajada finita e encaminha cada requisição a um servidor. Os experimentos seguem o enunciado [1]: rajadas de 30, 60, 90 e 120 requisições; três servidores homogêneos; capacidade simultânea de 15 posições por servidor; serviço constante de $S = 0,05$; horizonte $T = 200$; e dez execuções independentes.

Uma rajada termina muito antes de T , mas o período ocioso restante pertence ao experimento. Portanto, vazão e utilização são calculadas sobre as 200 unidades, e não sobre o tempo necessário para escoar a rajada. A comparação teórica também é transiente e possui a mesma população finita, em vez de representar chegadas contínuas por tempo infinito.

II. ARQUITETURA E PARAMETRIZAÇÃO

A. Simulador e políticas

A implementação em Go usa uma fila mínima de eventos. Uma chegada consulta o balanceador; havendo uma posição livre, o serviço começa e uma partida é agendada. Caso contrário, a requisição entra no buffer FIFO. Partidas precedem chegadas simultâneas. O relógio salta entre eventos, porém o resultado final avança até $T = 200$, incorporando a ociosidade posterior à rajada.

Aleatória sorteia um servidor primário uniforme. Round Robin mantém um índice local à execução. Fila Mais Curta minimiza requisições ativas mais enfileiradas, com desempate pelo menor identificador. O simulador registra ocupação, fila e conclusões depois de cada evento. Geradores distintos para




Figura 1. Intervalos de chegada da rajada de 120 requisições e densidade Bounded Pareto.

tráfego e roteamento asseguram o mesmo traço de chegada entre políticas em uma repetição.

B. Tráfego

Os intervalos são amostrados por transformação inversa de uma Pareto Limitada em $[L, U]$, cuja densidade é

$$f_X(x) = \frac{\alpha L^\alpha x^{-(\alpha+1)}}{1 - (L/U)^\alpha}, \quad L \leq x \leq U. \quad (1)$$

Usam-se $L = 0,0004$, $U = 0,04$ e $\alpha = 3 - 2\mathcal{H} = 1,4$ para $\mathcal{H} = 0,8$. A Fig. 1 confronta as amostras com a densidade teórica.

III. MODELO ANALÍTICO TRANSIENTE

Considere $m = 3$ servidores e encaminhamento independente com probabilidade $p = 1/m$, conforme exigido. Para uma rajada com N requisições, a ocupação do servidor s é

$$K_s \sim \text{Binomial}(N, 1/m). \quad (2)$$

O modelo concentra o lote em $t = 0$. Condicionado a $K_s = k$, um servidor com capacidade c_s e serviço S_s conclui a j -ésima requisição no instante $S_s \lceil j/c_s \rceil$. Assim, o tempo médio esperado é

$$R_0 = \frac{1}{N} \sum_{s=1}^m \sum_{k=0}^N \Pr[K_s = k] S_s \sum_{j=1}^k \left\lceil \frac{j}{c_s} \right\rceil. \quad (3)$$

Tabela I
MÉDIA DE DEZ EXECUÇÕES. Θ : REQ./UT; ρ : PORCENTAGEM; DEMAIS
COLUNAS: RESPOSTA MÉDIA.

N	Θ	$\rho(\%)$	Aleat.	RR	Menor fila
30	0,15	0,0167	0,05056	0,05000	0,05000
60	0,30	0,0333	0,05251	0,05115	0,05116
90	0,45	0,0500	0,05383	0,05202	0,05205
120	0,60	0,0667	0,05470	0,05284	0,05285

R_0 é uma referência transiente de lote instantâneo; a simulação distribui chegadas em tempos positivos e, em geral, reduz sua sobreposição. O limite sem fila é a média dos S_s .

Como todas as requisições terminam antes de 200, vazão e utilização teóricas no horizonte são

$$\Theta = \frac{N}{T}, \quad \rho = \frac{\sum_s E[K_s] S_s}{T \sum_s c_s}. \quad (4)$$

No caso homogêneo, $\rho = NS/(3cT)$. Na simulação, a forma equivalente é $\rho_{sim} = \sum_s \int_0^T B_s(t) dt / (T \sum_s c_s)$, onde $B_s(t)$ é o número de posições ativas. Essas definições medem o experimento completo; a taxa instantânea $1/E[X]$ caracteriza somente a intensidade interna da rajada e não é utilizada como vazão de longo prazo.

IV. MÉTODO EXPERIMENTAL

Para cada política e valor de N , executaram-se dez repetições com sementes reproduzíveis. A vazão é $C(T)/T$, onde $C(T)$ conta conclusões até 200. O tempo de resposta é a média entre chegada e partida das requisições concluídas. Também se mede a integral de ocupação, rejeições por buffer cheio e acionamentos do backup. A matriz completa e os extras são reproduzidos em Linux ou Windows com Go 1.26 por `go run ./cmd/simulador`; opções de linha de comando exportam resultados, repetições, tráfego e traços em CSV.

V. RESULTADOS E DISCUSSÃO

A Tabela I e a Fig. 2 mostram que todas as políticas concluem o lote. Por isso, a vazão é determinada por $N/200$, sem diferença entre políticas, e a utilização permanece abaixo de 0,067%. A política afeta o atraso: em $N = 120$, Round Robin reduz a resposta de 0,05470 para 0,05284 (3,4%) em relação à Aleatória.

A Fig. 3 evidencia a comparação correta de horizonte. A vazão analítica coincide com a simulação: 0,15, 0,30, 0,45 e 0,60. Para resposta, $S = 0,05$ é a referência sem fila, enquanto o lote instantâneo prevê 0,05015, 0,06283, 0,07797 e 0,09439. Os dados ficam próximos do limite sem fila porque o serviço progride durante a janela de chegadas; a diferença crescente confirma pequenas filas nas rajadas maiores. O modelo não usa Erlang-C nem uma taxa estacionária, pois não há fluxo infinito em equilíbrio.




Figura 2. Média e desvio-padrão de dez execuções, modelo finito e referência sem fila.




Figura 3. Round Robin: vazão no horizonte e comparação transiente do tempo de resposta.

Tabela II
POLÍTICAS ADICIONAIS EM SERVIDORES HETEROGÊNEOS, $N = 120$.

Política	Θ	Resposta	Redução vs. RR
Round Robin	0,600	0,06349	0,0%
RR Ponderado	0,600	0,04820	24,1%
Trabalho Mínimo	0,600	0,04815	24,2%
Poder de Duas	0,600	0,04820	24,1%

VI. EXTENSÕES, POLÍTICAS E ARQUITETURAS ADICIONAIS

A. Servidores heterogêneos

O primeiro extra substitui os três servidores idênticos por $(c_s, S_s) = (10, 0,06)$, $(15, 0,05)$ e $(20, 0,04)$. Assim, a taxa nominal c_s/S_s varia entre 166,7 e 500 requisições por unidade. Round Robin continua atribuindo um terço da carga a cada destino e, portanto, ignora essa diferença.

Foram implementadas três políticas adicionais. Round Robin Ponderado usa peso $w_s = c_s/S_s$ e o algoritmo suave: a cada decisão, soma-se w_s ao acumulador de cada servidor, escolhe-se o maior acumulador e subtrai-se $\sum_s w_s$ do vencedor. Trabalho Mínimo escolhe

$$s^* = \arg \min_s \frac{(a_s + q_s + 1)S_s}{c_s}, \quad (5)$$

onde a_s e q_s são ocupação e fila. Poder de Duas Escolhas sorteia dois primários distintos e aplica o mesmo escore apenas ao par. A decisão compara somente dois candidatos; o simulador ainda registra todos os estados para produzir os traços exigidos.

A Tabela II mostra que todas concluem 120 requisições, logo a vazão continua 0,60. A diferença está no atraso: Round Robin sobrecarrega o servidor mais lento, enquanto as três políticas cientes de capacidade obtêm resposta próxima. Trabalho Mínimo é ligeiramente melhor, mas consulta todos os servidores; Poder de Duas aproxima seu resultado observando somente dois.

B. Buffers finitos e backup

No segundo extra, cada primário tem buffer para duas requisições. Sem backup, a execução rejeita em média 5,9 requisições e produz $\Theta = 0,5705$. Um quarto servidor $(c, S) = (15, 0,05)$ fica fora do conjunto de roteamento normal. Quando o primário selecionado não possui posição nem buffer, a requisição é desviada ao backup. Em média, ocorrem 5,9 acionamentos, nenhuma rejeição, $\Theta = 0,60$ e resposta 0,05108.

C. Arquitetura hierárquica em dois níveis

O terceiro extra organiza quatro servidores heterogêneos em dois pools. Um balanceador global escolhe o pool z que minimiza

$$G_z = \frac{1 + \sum_{s \in z} (a_s + q_s)}{\sum_{s \in z} c_s/S_s}, \quad (6)$$

isto é, demanda agregada após a nova requisição dividida pela taxa nominal do pool. Em seguida, um balanceador local aplica




Figura 4. Políticas para servidores heterogêneos e efeito do backup com buffers finitos.




Figura 5. Roteamento plano e hierárquico na mesma topologia de dois pools.

Trabalho Mínimo somente aos dois servidores daquele pool. A separação permite que decisões locais permaneçam confinadas ao pool, enquanto o nível global troca apenas estado agregado entre grupos.

Como controle, a mesma topologia também executa Trabalho Mínimo plano, consultando diretamente os quatro servidores. As duas arquiteturas concluem as 120 requisições, com $\Theta = 0,60$ e resposta média 0,04684. Neste tráfego, a hierarquia preserva o resultado do balanceador centralizado; o experimento não mede latência de rede, falhas independentes dos pools nem custo real de propagação da telemetria, portanto não implica equivalência para implantações maiores.

VII. VALIDAÇÃO E LIMITAÇÕES

A validação possui quatro níveis. Primeiro, testes determinísticos exercitam precedência de partidas, capacidade simultânea, formação de fila, término no horizonte, integral de ocupação, rejeição e ativação do backup. Segundo, testes de política verificam ciclos independentes, desempates, exclusão do backup, proporção ponderada 1:2:3, escolha do menos carregado entre dois destinos e seleção global/local da hierarquia. Terceiro, sementes separadas garantem tráfego idêntico entre políticas. Por fim, os CSVs são regenerados diretamente pelo executável e os gráficos apenas transformam esses dados.

O modelo analítico e a simulação não são artificialmente forçados a coincidir no tempo de resposta. O modelo concentra o lote em $t = 0$ e calcula exatamente sua ocupação binomial; a simulação preserva intervalos Bounded Pareto positivos. Portanto, R_0 é uma referência transiente de concentração, não uma previsão estacionária nem um ajuste aos dados. A igualdade de vazão decorre somente de todas as requisições terminarem antes de T .

O mapeamento $\alpha = 3 - 2\mathcal{H}$ segue a parametrização solicitada, mas amostras independentes de uma distribuição marginal não demonstram, isoladamente, dependência de longa duração. Assim, o trabalho não afirma ter estimado $\mathcal{H}$ a partir do traço; ele usa $\mathcal{H} = 0,8$ para definir o expoente Pareto. Uma avaliação explícita de autocorrelação exigiria um gerador correlacionado adicional, fora do enunciado.

Os dez ensaios satisfazem o número pedido, mas ainda produzem incerteza visível no roteamento aleatório. Reportam-se média e desvio-padrão, sem interpretar diferenças menores que essa dispersão como vantagem conclusiva. Nos cenários de backup, utilização considera toda a capacidade provisionada, inclusive o servidor de reserva, escolha conservadora para planejamento de recursos.

VIII. CONCLUSÃO

O simulador implementa as três políticas obrigatórias, capacidade concorrente, filas finitas, monitoramento e dez repetições. O horizonte fixo corrige a interpretação de vazão e utilização: as rajadas são curtas e o sistema fica ocioso na maior parte das 200 unidades. O modelo binomial transiente preserva população finita, roteamento 1/3 e ondas de serviço. Nos extras, políticas cientes de capacidade reduzem o atraso em aproximadamente 24% nos servidores heterogêneos, o backup elimina perdas provocadas por buffers cheios e o roteamento hierárquico reproduz o atraso da decisão plana no cenário de dois pools.

DIVISÃO DE TRABALHO

Rodrigo Camargo: projetou e implementou o simulador de eventos discretos, a fila de eventos, o gerador Bounded Pareto, as políticas obrigatórias e adicionais, os cenários heterogêneo, de backup e hierárquico, as métricas, exportações CSV e testes automatizados. Também cuidou das sementes reproduzíveis e da execução final dos experimentos.

André Loubet: estruturou e revisou o relatório no formato IEEE, organizou tabelas e figuras, desenvolveu a visualização dos CSVs, confrontou resultados simulados e analíticos e revisou a apresentação das hipóteses, limitações e conclusões.

Atividades conjuntas: conferência dos parâmetros do enunciado, revisão do modelo transiente de lote finito, interpretação dos resultados, inspeção dos gráficos e validação do PDF e dos artefatos finais.

REFERÊNCIAS

- [1] C. A. Astudillo Trujillo e D. M. da Cunha, “Trabalho 1: Balanceador de Carga para um Sistema Distribuído,” MC714, Unicamp, ago. 2026.
- [2] S. M. Ross, *Introduction to Probability Models*, 12th ed. Academic Press, 2019.
- [3] M. Mitzenmacher, “The Power of Two Choices in Randomized Load Balancing,” *IEEE Transactions on Parallel and Distributed Systems*, vol. 12, no. 10, pp. 1094–1104, 2001.