

Balanceamento de Carga por Eventos Discretos para um Sistema Distribuído com Tráfego Bounded Pareto

Rodrigo Camargo André Loubet

RA 238257 RA 253333

MC714, Sistemas Distribuídos, Universidade Estadual de Campinas

Resumo. Este trabalho implementa e avalia um balanceador de carga para três servidores homogêneos. O simulador é orientado a eventos discretos, recebe chegadas com distribuição Bounded Pareto e compara as políticas aleatória, Round Robin e Fila Mais Curta. Cada servidor executa até quinze requisições simultâneas, com tempo de serviço determinístico de 0,05 unidades de tempo. Para cada combinação de política e rajada de 30, 60, 90 e 120 requisições, foram executadas dez repetições independentes. As métricas são vazão e tempo médio de resposta, confrontadas com um modelo analítico de roteamento justo. Round Robin e Fila Mais Curta preservaram menor atraso sob rajadas maiores; o roteamento aleatório sofre com desequilíbrios transitórios.

Index Terms. Balanceamento de carga, simulação de eventos discretos, Bounded Pareto, filas G/D/c, sistemas distribuídos.

I. INTRODUÇÃO

O balanceamento de carga distribui trabalho entre recursos equivalentes para evitar a ociosidade de alguns servidores e a sobrecarga de outros. Este projeto modela um front-end que recebe uma rajada finita de requisições e escolhe um dos três servidores. A implementação e os parâmetros obedecem ao enunciado do Trabalho 1 [1]: três servidores homogêneos, serviço constante de 0,05, capacidade simultânea de 15 requisições por servidor, horizonte máximo de 200 unidades de tempo e dez execuções independentes por cenário.

O objetivo é medir o efeito da política de despacho durante rajadas de intensidades crescentes. Além da simulação, foi construído um modelo analítico com probabilidade de encaminhamento 1/3 para cada servidor, permitindo separar o limite estacionário de capacidade do comportamento transitório das rajadas.

II. ARQUITETURA E PARAMETRIZAÇÃO

A. Simulador

A implementação em Go usa uma fila de prioridade de eventos. Um evento de chegada consulta o balanceador; se o servidor escolhido tiver menos de 15 requisições ativas, inicia-se o serviço e agenda-se sua partida. Caso contrário, a requisição entra em fila FIFO. Em cada partida, a próxima requisição da fila inicia imediatamente, quando existir. Partidas têm precedência sobre chegadas no mesmo instante, eliminando ambiguidade na liberação de capacidade.

A política aleatória sorteia um destino uniforme. Round Robin mantém um índice por execução e percorre ciclicamente os servidores. Fila Mais Curta escolhe o menor valor de

requisições ativas mais enfileiradas; empates usam o menor identificador. O estado do roteador e os geradores aleatórios são locais à repetição, portanto uma execução não altera outra. O simulador registra, depois de cada evento, tempo, servidor, número ativo, comprimento da fila e total concluído.

B. Tráfego Bounded Pareto

Os intervalos entre chegadas são amostrados em $[L, H]$ por transformação inversa. Para $L \leq x \leq H$, a distribuição empregada é

$$f_X(x) = \frac{\alpha L^\alpha x^{-(\alpha+1)}}{1 - (L/H)^\alpha}. \quad (1)$$

Usaram-se $L = 0,0004$ e $H = 0,04$. Para tráfego com dependência de longa duração, a aproximação usual relaciona o expoente à parametrização de Hurst: $\alpha = 3 - 2\mathcal{H}$. Logo, $\mathcal{H} = 0,8$ resulta em $\alpha = 1,4$. Os valores são limitados, evitando amostras infinitas e preservando o caráter de rajada.

III. MODELO ANALÍTICO

O modelo supõe roteamento justo, logo a taxa de chegada de cada servidor é $\lambda_s = \lambda/3$, em que $\lambda = 1/E[X]$ vem do primeiro momento da Bounded Pareto. O tempo de serviço é determinístico, com taxa por posição $\mu = 1/0,05 = 20$, e cada servidor possui $c = 15$ posições. A utilização por servidor é

$$\rho = \frac{\lambda_s}{c\mu}. \quad (2)$$

Para $\rho < 1$, estima-se a espera pela aproximação G/D/c baseada em Erlang-C. Seja $C(c, \rho)$ a probabilidade de esperar do modelo M/M/c e $C_a^2 = \text{Var}(X)/E[X]^2$ a variabilidade dos intervalos de chegada. Como o serviço é determinístico, $C_s^2 = 0$; assim,

$$W_q \approx \frac{C(c, \rho)}{c\mu - \lambda_s} \frac{C_a^2 + C_s^2}{2}, \quad R = 0,05 + W_q. \quad (3)$$

A vazão de regime é $T = \min(\lambda, 3c\mu)$. Para os parâmetros empregados, o modelo estacionário fornece $T = 847,47$ requisições por unidade de tempo, $R = 0,11433$ e utilização $\rho \approx 0,94$. Como as rajadas do enunciado são finitas, complementa-se essa referência com um horizonte $T_N = NE[X] + 0,05$ e vazão N/T_N , válida quando a capacidade simultânea absorve a carga; nesse caso a resposta analítica reduz-se ao serviço 0,05.

Tabela I
MÉDIAS DE DEZ SIMULAÇÕES POR CENÁRIO. T_s : VAZÃO SIMULADA; R_s :
TEMPO MÉDIO DE RESPOSTA.

Política	Rajada	T_s	R_s
Aleatória	30	359,19	0,05000
Aleatória	60	470,79	0,05203
Aleatória	90	524,69	0,05304
Aleatória	120	572,15	0,05388
Round Robin	30	359,19	0,05000
Round Robin	60	485,98	0,05106
Round Robin	90	556,07	0,05163
Round Robin	120	594,55	0,05198
Fila Mais Curta	30	359,19	0,05000
Fila Mais Curta	60	484,31	0,05107
Fila Mais Curta	90	549,87	0,05165
Fila Mais Curta	120	593,93	0,05201

IV. MÉTODO EXPERIMENTAL

Foram avaliadas as três políticas com rajadas de 30, 60, 90 e 120 requisições. Cada ponto é a média de dez execuções independentes, com sementes reproduzíveis. Os fluxos de chegada usam geradores separados dos sorteios do roteamento; consequentemente, uma mesma repetição apresenta o mesmo traço de chegada para todas as políticas. Chegadas ou partidas posteriores ao horizonte de 200 são descartadas da observação. A vazão observada é o número concluído dividido pelo tempo simulado, e o tempo de resposta é a média entre chegada e partida das requisições concluídas.

V. RESULTADOS E DISCUSSÃO

A Fig. 1 confirma a parametrização Bounded Pareto com $\mathcal{H} = 0,8$ ($\alpha = 1,4$): os intervalos simulados concentram-se perto de $L = 0,0004$, com cauda até $H = 0,04$. O primeiro momento teórico dessa distribuição é $E[X] \approx 0,00118$, ou seja, $\lambda \approx 847$, de modo que o tempo de serviço 0,05 é muito maior que o intervalo típico e as chegadas chegam em rajada.




Figura 1. Densidade dos intervalos de chegada na rajada de 120 requisições e PDF teórica Bounded Pareto.

A Tabela I e a Fig. 2 reportam a média e o desvio-padrão das dez execuções. Em 30 requisições todas as políticas coincidem com o serviço 0,05: a capacidade de 15 posições por servidor

absorve a rajada. Com a carga, o roteamento aleatório degrada vazão e atraso; Round Robin e Fila Mais Curta permanecem próximos. Em 120 requisições, Round Robin reduz o tempo médio de 0,05388 para 0,05198 ($\approx 3,5\%$) em relação à política aleatória.




Figura 2. Vazão e tempo de resposta: média $\pm$ desvio-padrão de 10 execuções, contra o modelo de horizonte finito.

A Fig. 3 faz a comparação quantitativa exigida. O modelo estacionário com probabilidade 1/3 superestima vazão (847 vs. 359–595) e atraso (0,114 vs. $\approx 0,05$), porque assume fluxo renovador indefinido com $\rho \approx 0,94$. O horizonte finito N/T_N acompanha a simulação: 351 vs. 359 em 30 requisições e 626 vs. 595 em 120. A diferença residual cresce com a rajada e coincide com o surgimento de filas.

A Fig. 4 confronta a hipótese analítica 1/3 com a fração média de requisições atribuídas a cada servidor. Round Robin realiza exatamente o balanceamento justo; Fila Mais Curta permanece próxima de 1/3; a política aleatória desvia até cerca de 38%/28% nos servidores extremos nas rajadas menores. Isso explica o atraso extra: o modelo justo descreve Round Robin, não o sorteio uniforme em rajadas curtas.

O monitoramento de estado mostra que a ocupação agregada atinge o teto $3 \times 15 = 45$ na rajada de 120, enquanto as filas permanecem curtas: comprimento máximo de 5 requisições no roteamento aleatório e de 3 em Round Robin e Fila Mais Curta. O horizonte de 200 nunca descarta requisições nos cenários avaliados.

VI. CONCLUSÃO

O simulador implementa as três políticas exigidas, capacidade finita de processamento, tráfego Bounded Pareto, monitoramento de filas e média de dez repetições. A capacidade concorrente elimina filas nas menores rajadas; sob carga maior,




Figura 3. Round Robin: simulação versus modelo de horizonte finito e modelo estacionário com roteamento 1/3.




Figura 4. Participação média de cada servidor nas dez execuções, comparada à probabilidade analítica 1/3.

DIVISÃO DE TRABALHO

Rodrigo Camargo: implementação do código-fonte do simulador, incluindo motor de eventos discretos, servidores, políticas de balanceamento, geração de tráfego, métricas e testes. **André Loubet:** redação, organização e revisão do relatório técnico, incluindo a apresentação dos resultados, gráficos e comparação entre simulação e modelo analítico.

REFERÊNCIAS

- [1] C. A. Astudillo Trujillo e D. M. da Cunha, "Trabalho 1: Balanceador de Carga para um Sistema Distribuído," MC714, Sistemas Distribuídos, Instituto de Computação, Unicamp, ago. 2026.
- [2] A. O. Allen, *Probability, Statistics, and Queueing Theory with Computer Science Applications*, 2nd ed. Academic Press, 1990.
- [3] D. Bertsekas and R. Gallager, *Data Networks*, 2nd ed. Prentice Hall, 1992.

Round Robin e Fila Mais Curta distribuem melhor o trabalho que a política aleatória. O modelo $G/D/c$ com roteamento justo fornece uma base quantitativa para a comparação, e sua divergência das rajadas finitas deve ser interpretada como efeito de transiente, não como falha de capacidade. Extensões naturais são servidores heterogêneos e um servidor de backup.