

Balanceador de Carga com Filas M/M/1 para um Sistema Distribuído

Rodrigo Camargo André Loubet

RA 238257 RA 253333

MC714, Sistemas Distribuídos, Universidade Estadual de Campinas

Resumo—Implementamos em Go um simulador de eventos discretos para um balanceador instantâneo que encaminha um processo de Poisson para três réplicas homogêneas com filas FCFS ilimitadas. Comparamos Escolha Aleatória, Round Robin e Fila Mais Curta em cinco cargas estáveis, usando dez réplicas de 5000 unidades e aquecimento de 500. Para a política aleatória, a decomposição Poisson produz três filas M/M/1 independentes e fornece a referência analítica. A simulação confirma vazão, utilização, Lei de Little e a ordenação de resposta entre as políticas. Em $\lambda = 3,3$, as filas crescem sem equilíbrio como previsto pelo modelo fluido.

I. ARQUITETURA E MÉTODO

O front-end recebe cada requisição e seleciona uma das três réplicas antes da admissão. O dispatcher não consome tempo. Cada réplica tem uma única thread, fila FCFS ilimitada e tempo de serviço exponencial de média $1/\mu = 1$. Chegadas são exponenciais independentes com taxa total λ . O relógio virtual processa chegadas e partidas numa fila mínima de eventos. Partidas vencem chegadas no mesmo instante, garantindo que a ocupação observada na decisão seja consistente.

A configuração de linha de comando escolhe `random`, `round_robin`, `shortest_queue` ou todas. Aleatória sorteia cada destino com probabilidade $1/3$. Round Robin cicla 1, 2, 3. Fila Mais Curta escolhe o menor número de requisições em execução mais espera e sorteia uniformemente os empates. O programa registra para cada evento instante, população total, ocupação por fila e conclusões. Assim, o rastreamento distingue a decisão centralizada da execução independente nas réplicas.

Foram avaliados $\lambda \in \{0,6, 1,2, 1,8, 2,4, 2,7\}$, cada política e dez sementes. Cada execução dura $T = 5000$ e descarta os primeiros 500 instantes. Medimos vazão X , resposta média $E[R]$, população média $E[N]$ pela área sob $N(t)$ e utilização por servidor U_i . Os intervalos apresentados são $t_{0,975,9s}/\sqrt{10}$. Para manter a comparação controlada, a réplica de mesmo índice recebe a mesma sequência de chegadas nas três políticas e usa fontes independentes para serviço e roteamento.

II. MODELO ANALÍTICO PARA ESCOLHA ALEATÓRIA

Se $N(t)$ é Poisson de taxa λ , o *splitting* independente por três destinos com probabilidade $1/3$ gera processos $N_i(t)$ Poisson independentes, todos com

$$\lambda_i = \lambda/3. \quad (1)$$

Tabela I
MODELO M/M/1 DA RÉPLICA SOB ALEATÓRIA, COM $\mu = 1$.

λ	p_0	U_i	$E[N_i]$	$E[T_Q]$	$E[R]$	X
0,6	0,80	0,20	0,250	0,250	1,250	0,6
1,2	0,60	0,40	0,667	0,667	1,667	1,2
1,8	0,40	0,60	1,500	1,500	2,500	1,8
2,4	0,20	0,80	4,000	4,000	5,000	2,4
2,7	0,10	0,90	9,000	9,000	10,000	2,7

Logo, cada réplica sob Aleatória é exatamente uma M/M/1. Com $\rho = \lambda/(3\mu)$, sua distribuição estacionária é

$$p_k = (1 - \rho)\rho^k, \quad k \geq 0, \quad (2)$$

e existe somente se $\lambda < 3\mu$. Das médias geométricas segue

$$U_i = \rho, \quad E[N_i] = \frac{\rho}{1 - \rho}, \quad (3)$$

$$E[T_Q] = \frac{\rho}{\mu - \lambda/3}, \quad E[R] = \frac{1}{\mu - \lambda/3}. \quad (4)$$

Em equilíbrio, toda chegada aceita é atendida por alguma réplica. Por conservação de trabalho, $X = \lambda$ e a utilização média é $\lambda/(3\mu)$ também para Round Robin e Fila Mais Curta. A política altera a distribuição de espera, não a capacidade de serviço. A Tabela I contém a referência analítica por réplica.

III. RESULTADOS ESTÁVEIS

A Figura 1 compara a curva analítica com os pontos simulados e ICs de 95%. Aleatória acompanha o modelo, inclusive perto de $\rho = 0,9$. Por exemplo, em $\lambda = 2,7$, $E[R]_{sim} = 9,712 \pm 0,677$ contra 10 analítico. A diferença é compatível com a variabilidade finita das dez réplicas. A vazão observada nas 15 configurações ficou entre 0,595 e 2,695, com IC máximo 0,018. As utilizações por réplica ficaram entre 0,193 e 0,908, centradas nas previsões de 0,2 a 0,9. Isso confirma a conservação de trabalho exigida para as três políticas.

A Tabela II mostra as médias e ICs de resposta, além do ganho sobre Aleatória. A ordenação $E[R]_{Fila\ Curta} \leq E[R]_{RR} \leq E[R]_{Aleat.}$ vale em todas as cargas. Round Robin elimina a variação introduzida pelo sorteio de destinos. Fila Mais Curta também usa informação atual de congestionamento e evita encaminhar para uma réplica maior quando há alternativa. O ganho cresce com a carga. Em $\lambda = 2,7$, Round Robin reduz a resposta em 31,6% e Fila Mais Curta em 59,8%.




Figura 1. Resposta simulada com IC de 95% e curva M/M/1 para Aleatória.

Tabela II
RESPOSTA MÉDIA $\pm$ IC 95% E GANHO SOBRE ALEATÓRIA.

λ	Aleatória	RR	ganho RR	Fila curta	ganho F
0,6	1,243 $\pm$ 0,019	1,060 $\pm$ 0,009	14,7%	1,022 $\pm$ 0,011	17,8%
1,2	1,666 $\pm$ 0,056	1,279 $\pm$ 0,022	23,2%	1,125 $\pm$ 0,014	32,5%
1,8	2,553 $\pm$ 0,114	1,853 $\pm$ 0,093	27,4%	1,437 $\pm$ 0,053	43,7%
2,4	4,753 $\pm$ 0,278	3,187 $\pm$ 0,126	33,0%	2,155 $\pm$ 0,065	54,7%
2,7	9,712 $\pm$ 0,677	6,644 $\pm$ 0,824	31,6%	3,904 $\pm$ 0,315	59,8%

A Lei de Little foi medida no sistema inteiro como $E[N] = XE[R]$. O maior erro absoluto entre as 15 combinações foi 0,127, para Aleatória em $\lambda = 2,7$. Os outros ficaram abaixo de 0,060, exceto efeitos de filas longas no limite de carga. A integração temporal evita o viés de usar somente a média observada nas chegadas.

IV. INSTABILIDADE EM $\lambda = 3,3$

Com $\lambda = 3,3$, $\rho = 1,1$ e a capacidade total é $3\mu = 3$. Não existe distribuição estacionária nem valores finitos para p_k , $E[N_i]$, $E[T_Q]$ e $E[R]$. A aproximação fluida de rede é

$$N(t) \approx N(0) + (\lambda - 3\mu)t = N(0) + 0,3t. \quad (5)$$

A Figura 2 mostra a trajetória registrada na primeira réplica de cada política e a reta $0,3t$. Em $T = 5000$, a reta prevê 1500 requisições acumuladas. As médias finais foram $1580,6 \pm 73,9$, $1574,0 \pm 75,4$ e $1569,8 \pm 75,1$ para Aleatória, Round Robin e Fila Mais Curta. As diferenças de curto prazo vêm da variância de chegadas e serviços. Nenhuma política muda




Figura 2. Crescimento de $N(t)$ em $\lambda = 3,3$ e aproximação fluida.

a inclinação assintótica, pois todas recebem mais trabalho do que a capacidade conjunta pode concluir.

V. REPRODUTIBILIDADE E CONCLUSÃO

O executável exporta médias, ICs, réplicas e rastreamento em CSV. O README explica compilação e execução em Linux e Windows. Os testes verificam o modelo M/M/1, a instabilidade, a Lei de Little, o rastreamento de filas e a ordenação das políticas. Rodrigo Camargo implementou simulador, políticas, métricas, testes e experimentos. André Loubet estruturou o relatório, os gráficos e a análise quantitativa. Ambos conferiram os parâmetros e os artefatos finais.

O resultado mostra a separação essencial entre capacidade e despacho. A conservação de trabalho preserva vazão e utilização na região estável, enquanto a informação de fila reduz atraso. A validação de Aleatória pelo modelo M/M/1 ancora essa comparação. Acima da capacidade total, nenhuma política de balanceamento torna o sistema estável. São necessários mais servidores ou limitação de admissão.

REFERÊNCIAS

- [1] C. A. Astudillo Trujillo e D. M. da Cunha, “Trabalho 1: Balanceador de Carga para um Sistema Distribuído,” MC714, Unicamp, ago. 2026.
- [2] S. M. Ross, *Introduction to Probability Models*, 12th ed. Academic Press, 2019.

Tabela III
POPULAÇÃO MÉDIA $E[N]$ COM IC DE 95%.

λ	Aleatória	RR	Fila curta
0,6	0,740 $\pm$ 0,019	0,631 $\pm$ 0,014	0,608 $\pm$ 0,014
1,2	2,005 $\pm$ 0,071	1,539 $\pm$ 0,029	1,354 $\pm$ 0,019
1,8	4,609 $\pm$ 0,214	3,345 $\pm$ 0,174	2,593 $\pm$ 0,098
2,4	11,375 $\pm$ 0,702	7,622 $\pm$ 0,327	5,151 $\pm$ 0,179
2,7	26,262 $\pm$ 1,877	17,959 $\pm$ 2,260	10,539 $\pm$ 0,867