

Balanceamento de Carga por Eventos Discretos para um Sistema Distribuído com Tráfego Bounded Pareto

Rodrigo Camargo André Loubet
RA 238257 RA 253333

MC714, Sistemas Distribuídos, Universidade Estadual de Campinas

Resumo. Este trabalho implementa e avalia um balanceador de carga para três servidores. O simulador orientado a eventos discretos recebe rajadas Bounded Pareto e compara as políticas Aleatória, Round Robin e Fila Mais Curta. Cada servidor homogêneo executa até quinze requisições simultâneas, com serviço determinístico de 0,05. Cada cenário usa horizonte fixo de 200 unidades e dez repetições. A análise emprega um modelo transiente de lote finito com roteamento justo, evitando hipóteses de regime estacionário incompatíveis com a rajada. Também são avaliados servidores heterogêneos, roteamento ciente de capacidade e um servidor de backup para estouro de buffers.

Index Terms. Balanceamento de carga, simulação de eventos discretos, Bounded Pareto, modelo transiente, sistemas distribuídos.

I. INTRODUÇÃO

O trabalho modela um front-end que recebe uma rajada finita e encaminha cada requisição a um servidor. Os experimentos seguem o enunciado [1]: rajadas de 30, 60, 90 e 120 requisições; três servidores homogêneos; capacidade simultânea de 15 posições por servidor; serviço constante de $S = 0,05$; horizonte $T = 200$; e dez execuções independentes.

Uma rajada termina muito antes de T , mas o período ocioso restante pertence ao experimento. Portanto, vazão e utilização são calculadas sobre as 200 unidades, e não sobre o tempo necessário para escoar a rajada. A comparação teórica também é transiente e possui a mesma população finita, em vez de representar chegadas contínuas por tempo infinito.

II. ARQUITETURA E PARAMETRIZAÇÃO

A. Simulador e políticas

A implementação em Go usa uma fila mínima de eventos. Uma chegada consulta o balanceador; havendo uma posição livre, o serviço começa e uma partida é agendada. Caso contrário, a requisição entra no buffer FIFO. Partidas precedem chegadas simultâneas. O relógio salta entre eventos, porém o resultado final avança até $T = 200$, incorporando a ociosidade posterior à rajada.

Aleatória sorteia um servidor primário uniforme. Round Robin mantém um índice local à execução. Fila Mais Curta minimiza requisições ativas mais enfileiradas, com desempate pelo menor identificador. O simulador registra ocupação, fila e conclusões depois de cada evento. Geradores distintos para




Figura 1. Intervalos de chegada da rajada de 120 requisições e densidade Bounded Pareto.

tráfego e roteamento asseguram o mesmo traço de chegada entre políticas em uma repetição.

B. Tráfego

Os intervalos são amostrados por transformação inversa de uma Pareto Limitada em $[L, U]$, cuja densidade é

$$f_X(x) = \frac{\alpha L^\alpha x^{-(\alpha+1)}}{1 - (L/U)^\alpha}, \quad L \leq x \leq U. \quad (1)$$

Usam-se $L = 0,0004$, $U = 0,04$ e $\alpha = 3 - 2\mathcal{H} = 1,4$ para $\mathcal{H} = 0,8$. A Fig. 1 confronta as amostras com a densidade teórica.

III. MODELO ANALÍTICO TRANSIENTE

Considere $m = 3$ servidores e encaminhamento independente com probabilidade $p = 1/m$, conforme exigido. Para uma rajada com N requisições, a ocupação do servidor s é

$$K_s \sim \text{Binomial}(N, 1/m). \quad (2)$$

O modelo concentra o lote em $t = 0$. Condicionado a $K_s = k$, um servidor com capacidade c_s e serviço S_s conclui a j -ésima requisição no instante $S_s \lceil j/c_s \rceil$. Assim, o tempo médio esperado é

$$R_0 = \frac{1}{N} \sum_{s=1}^m \sum_{k=0}^N \Pr[K_s = k] S_s \sum_{j=1}^k \left\lceil \frac{j}{c_s} \right\rceil. \quad (3)$$

Tabela I
MÉDIA DE DEZ EXECUÇÕES. Θ : REQ./UT; ρ : PORCENTAGEM; DEMAIS
COLUNAS: RESPOSTA MÉDIA.

N	Θ	$\rho(\%)$	Aleat.	RR	Menor fila
30	0,15	0,0167	0,05056	0,05000	0,05000
60	0,30	0,0333	0,05251	0,05115	0,05116
90	0,45	0,0500	0,05383	0,05202	0,05205
120	0,60	0,0667	0,05470	0,05284	0,05285

R_0 é uma referência transiente de lote instantâneo; a simulação distribui chegadas em tempos positivos e, em geral, reduz sua sobreposição. O limite sem fila é a média dos S_s .

Como todas as requisições terminam antes de 200, vazão e utilização teóricas no horizonte são

$$\Theta = \frac{N}{T}, \quad \rho = \frac{\sum_s E[K_s] S_s}{T \sum_s c_s}. \quad (4)$$

No caso homogêneo, $\rho = NS/(3cT)$. Na simulação, a forma equivalente é $\rho_{sim} = \sum_s \int_0^T B_s(t) dt / (T \sum_s c_s)$, onde $B_s(t)$ é o número de posições ativas. Essas definições medem o experimento completo; a taxa instantânea $1/E[X]$ caracteriza somente a intensidade interna da rajada e não é utilizada como vazão de longo prazo.

IV. MÉTODO EXPERIMENTAL

Para cada política e valor de N , executaram-se dez repetições com sementes reproduzíveis. A vazão é $C(T)/T$, onde $C(T)$ conta conclusões até 200. O tempo de resposta é a média entre chegada e partida das requisições concluídas. Também se mede a integral de ocupação, rejeições por buffer cheio e acionamentos do backup. A matriz completa e os extras são reproduzidos em Linux ou Windows com Go 1.26 por `go run ./cmd/simulador`; opções de linha de comando exportam resultados, repetições, tráfego e traços em CSV.

V. RESULTADOS E DISCUSSÃO

A Tabela I e a Fig. 2 mostram que todas as políticas concluem o lote. Por isso, a vazão é determinada por $N/200$, sem diferença entre políticas, e a utilização permanece abaixo de 0,067%. A política afeta o atraso: em $N = 120$, Round Robin reduz a resposta de 0,05470 para 0,05284 (3,4%) em relação à Aleatória.

A Fig. 3 evidencia a comparação correta de horizonte. A vazão analítica coincide com a simulação: 0,15, 0,30, 0,45 e 0,60. Para resposta, $S = 0,05$ é a referência sem fila, enquanto o lote instantâneo prevê 0,05015, 0,06283, 0,07797 e 0,09439. Os dados ficam próximos do limite sem fila porque o serviço progride durante a janela de chegadas; a diferença crescente confirma pequenas filas nas rajadas maiores. O modelo não usa Erlang-C nem uma taxa estacionária, pois não há fluxo infinito em equilíbrio.

A. Pontos extras

Servidores heterogêneos foram configurados como $(c_s, S_s) = (10, 0,06)$, $(15, 0,05)$ e $(20, 0,04)$. A política Trabalho Mínimo escolhe o menor valor $(a_s + q_s + 1)S_s/c_s$,




Figura 2. Média e desvio-padrão de dez execuções, modelo finito e referência sem fila.




Figura 3. Round Robin: vazão no horizonte e comparação transiente do tempo de resposta.

incorporando ocupação, fila, capacidade e velocidade. Em $N = 120$, ela mantém $\Theta = 0,60$ e reduz a resposta de 0,06349 (Round Robin) para 0,04815.

No segundo extra, cada primário possui buffer para duas requisições. Sem backup, há em média 5,9 rejeições e $\Theta = 0,5705$. Um quarto servidor de backup, excluído do roteamento normal, é acionado somente quando o destino primário não admite outra requisição. Ele recebe em média 5,9 requisi-

ções, elimina as rejeições e restaura $\Theta = 0,60$, com resposta 0,05108.

VI. CONCLUSÃO

O simulador implementa as três políticas obrigatórias, capacidade concorrente, filas finitas, monitoramento e dez repetições. O horizonte fixo corrige a interpretação de vazão e utilização: as rajadas são curtas e o sistema fica ocioso na maior parte das 200 unidades. O modelo binomial transiente preserva população finita, roteamento 1/3 e ondas de serviço, oferecendo uma comparação compatível com o experimento. Os extras demonstram ganho de roteamento ciente de capacidade e recuperação de estouro por backup.

DIVISÃO DE TRABALHO

Rodrigo Camargo: simulador, políticas, tráfego, métricas, extensões e testes. **André Loubet:** redação, organização e revisão do relatório, gráficos e comparação analítica.

REFERÊNCIAS

- [1] C. A. Astudillo Trujillo e D. M. da Cunha, “Trabalho 1: Balanceador de Carga para um Sistema Distribuído,” MC714, Unicamp, ago. 2026.
- [2] S. M. Ross, *Introduction to Probability Models*, 12th ed. Academic Press, 2019.